

Algoritmos de Machine Learning aplicados a la proliferación de cianobacteria en los lagos de Atitlán y Amatitlán.

Universidad del Valle de Guatemala
Ciencia de Datos, sección 10
Castellanos, I; Pérez, M. y Rodríguez R.

Introducción

Los lagos Atitlán y Amatitlán poseen gran importancia ambiental, económica y cultural para Guatemala, pero enfrentan problemas asociados con la proliferación de cianobacterias. En este estudio se utilizaron imágenes satelitales Sentinel-2 para analizar su distribución espacial y evolución temporal entre 2025 y 2026. Mediante indicadores de clorofila-a, NDVI y NDWI, se identificaron posibles floraciones, zonas de acumulación y diferencias en el comportamiento de ambos lagos.

Descripción de los datos

Se han usado datos provenientes del satélite Sentinel-2A, 2B y 2C, de los lagos de Atitlán y Amatitlán en Guatemala. Se han tomado 11 de cada lago (22 en total) muestras con la siguiente información:

- Estimación de clorofila-a asociada a cianobacteria (cyanobacteria_chla, $\mu\text{g/L}$);
- NDVI, usando B04 y B08;
- NDWI, usando B03 y B08;
- máscara de píxeles válidos de agua sin nube.

En ambos lagos se tienen fechas distintas:

- Lago de Amatitlán: 2025-01-28, 2025-04-15, 2025-04-28, 2025-11-24, 2026-01-08, 2026-02-02, 2026-02-07, 2026-03-29, 2026-04-13, 2026-04-28, 2026-06-19.
- Lago de Atitlán: 2025-01-18, 2025-04-13, 2025-05-13, 2025-07-17, 2025-11-21, 2025-12-29, 2026-02-12, 2026-03-24, 2026-04-13, 2026-04-28, 2026-07-22.

El conjunto de datos creado conservó los valores de las bandas B03, B04, B04 y B08, sus coordenadas x, y del plano basado en los límites con los que se extrajo cada archivo y la cantidad de píxeles válidos de cada grupo. También se calcularon el NDCI, NDVI, NDWI, clorofila-a estimada, la proporción de agua, tierra/vegetación y otros.

La variable objetivo fue creada mediante una regla definida con un umbral de clorofila-a estimada, el cual define que si este parámetro es menor a 12 µg/L entonces se considera de baja presencia de cianobacteria, en caso contrario se considera alta presencia de cianobacteria (Chorus y Welker, 2021).

Modelos

Se generaron 2 tipos de modelos, el primer grupo fue entrenado con los píxeles originales (10 m x 10 m), mientras que el segundo grupo fue entrenado con píxeles agrupados en (1000 m x 1000 m).

Cuadro 1: Modelos usados en la predicción de presencia alta y baja de cianobacterias, en píxeles originales.

Modelo	Hiperparámetros del mejor modelo
Regresión logística	C: 10 penalty: l2 solver': liblinear
Random Forest	max_depth: 7 max_features': sqrt min_samples_leaf: 1 min_samples_split: 5 n_estimators: 200
XGBoost	colsample_bytree: 1 learning_rate: 0.1 max_depth': 5 n_estimators': 300 subsample: 1

El segundo grupo de tipos de modelos ha consistido en aquellos sobre los que se ha realizado una validación espacial. En este caso, se ha dividido cada lago en una cuadrícula de $1000m \times 1000m$; los datos se han proyectado al sistema de coordenadas WGS 84 / UTM zona 15N (EPSG:322615), la cual abarca parte del hemisferio norte entre $96^{\circ}O - 90^{\circ}O$ y entre el ecuador y $84^{\circ}N$, abarcando partes del este de Canadá, Estados Unidos, el sur de México y Guatemala.

Con esta base se han implementado nuevamente los modelos:

Cuadro 2: Modelos usados en la predicción de presencia alta y baja de cianobacterias, en píxeles proyectados a WGS 84 / UTM zona 15N (EPSG:322615).

Modelo	Hiperparámetros del mejor modelo
Regresión logística	C: 10 penalty: l2 solver': liblinear
Random Forest	max_depth: 7 max_features': sqrt min_samples_leaf: 1 min_samples_split: 5 n_estimators: 200
XGBoost	colsample_bytree: 1.0 learning_rate: 0.1 max_depth': 5 n_estimators': 300 subsample: 1.0

Con estos datos se han implementado dos modelos más, en los que el entrenamiento fue hecho a base de datos exclusivos de un lago mientras que la prueba fue hecha con datos exclusivos del otro lago. Esto con el fin de observar su capacidad de generalización.

Cuadro 3: Modelos usados en el experimento A, en el que los datos del entrenamiento corresponden al lago de Atitlán, mientras que la prueba corresponde al lago de Amatitlán.

Modelo	Hiperparámetros del mejor modelo
Regresión logística	C: 1.0 penalty: l2 solver': lbfgs
Random Forest	max_depth: None max_features': sqrt min_samples_leaf: 1 min_samples_split: 2 n_estimators: 100
XGBoost	colsample_bytree: None learning_rate: None max_depth': None n_estimators': None subsample: None

Cuadro 4: Modelos usados en el experimento B, en el que los datos del entrenamiento corresponden al lago de Amatitlán, mientras que la prueba corresponde al lago de Atitlán.

Modelo	Hiperparámetros del mejor modelo
Regresión logística	C: 1.0 penalty: l2 solver': lbfgs
Random Forest	max_depth: None max_features': sqrt min_samples_leaf: 1 min_samples_split: 2 n_estimators: 100
XGBoost	colsample_bytree: None learning_rate: None max_depth': None n_estimators': None subsample: None

Resultados

Cuadro 5: Métricas de los modelos usados en la predicción de presencia alta y baja de cianobacterias con píxeles originales, tomando la presencia baja como clase positiva.

Modelos	Precision	Recall	F1-score	ROC-AUC
Regresión logística	0.9397	0.9047	0.9218	0.9692
Random Forest	0.9401	0.9107	0.9251	0.9717
XGBoost	0.9451	0.9315	0.9382	0.9801

Figura 1: Matriz de confusión del algoritmo de regresión logística para el modelo entrenado con píxeles originales.




Figura 2: Matriz de confusión del algoritmo de Random Forest para el modelo entrenado con píxeles originales.





Figura 3: Matriz de confusión del algoritmo de XGBoost para el modelo entrenado con píxeles originales.



Cuadro 6: Métricas de los modelos usados en la predicción de presencia alta y baja de cianobacterias con proyectados.

Modelos	Precision	Recall	F1-score	ROC-AUC
Regresión logística	0.7500	0.9	0.8182	0.9091
Random Forest	0.7692	1.0	0.9091	0.9091
XGBoost	0.7692	1.0	0.9000	0.9000

Cuadro 7: Diferencia de las métricas de los modelos usados en la predicción de presencia alta y baja de cianobacterias. Se ha restado la versión original a la versión espacial.

Modelos	Precision	Recall	F1-score	ROC-AUC
Regresión logística	-0.083	-0.1	-0.091	-0.041
Random Forest	-0.064	0.0	-0.040	-0.074
XGBoost	-0.140	0.0	-0.083	-0.050

Cuadro 8. Comparación de las métricas del experimento A y B.

Experimento	Modelo	Precision	Recall	F1	ROC-AUC
Experimento A	Regresión Logística	0.000	0.000	0.000	1.000

Train: Atitlán	Random Forest	1.000	1.000	1.000	1.000
	XGBoost	0.917	0.833	0.909	1.000
Test: Amatitlán					
Experimento B Train: Amatitlán Test: Atitlán	Regresión Logística	0.000	0.000	0.000	0.807
	Random Forest	0.774	0.889	0.828	0.907
	XGBoost	0.913	0.778	0.840	0.849

Discusión

De los modelos generados para la predicción de presencia alta y baja de cianobacterias con píxeles originales, el que mejor capacidad predictiva presentó fue el modelo de XGBost, respecto a la métrica F1-score, la cual fue elegida debido a que se tenía un desbalance leve entre las etiquetas y se les decidió dar el mismo valor a ambas.

En todas las métricas y en la matriz de confusión analizadas el mejor modelo fue el XGBoost, el cual demostró tener una mejor capacidad de predicción. El resultado tampoco fue mucho mejor que los otros modelos, por lo que si se requirier explicabilidad, la regresión logística puede ser una excelente opción, ya que tiene un f1-score solo 0.023 por debajo del XGBoost.

Si se desea generar un plan de limpieza, catalogar incorrectamente una zona de baja presencia como si fuera de alta presencia, puede generar inversión más elevada de la necesaria para los procesos de limpieza. El caso contrario, puede evitar que zonas realmente afectadas sean consideradas para la limpieza, generando aún más acumulación elevada que no sea tratada, generando así problemas para la salud de las poblaciones cercanas o la flora y fauna.

Consideramos que se debe dar más importancia a no predecir incorrectamente las zonas de alta presencia, ya que estas pueden ocasionar problemas de salud o de pérdida de flora y fauna. La métrica más útil sería el recall, (tomando alta presencia como positiva), en este caso el modelo XGBoost es considerado el mejor.

Se tiene que, para los modelos con datos proyectados, los valores de los hiperparámetros han resultado ser iguales que los de los píxeles originales. A pesar de esto, las métricas para estos experimentos resultaron ser considerablemente menores que las de los modelos originales, como puede observarse en el **Cuadro7**. Es por ello por lo que se recomienda usar estos primeros modelos, ya que además de los valores de las métricas, se tiene que estos requieren un preprocesamiento menos complejo que aquel de los datos proyectados, lo que se traduce en menor capacidad de cómputo.

No obstante, se tiene que los modelos con datos proyectados presentan una generalización considerable de los datos, en especial los modelos de Random Forest y XGBoost, como puede observarse en los resultados de las métricas del **Cuadro8**. En este, se observa que los valores son muy cercanos en las métricas para estos dos modelos y que los valores son considerablemente altos en general. El modelo de Regresión Logística no generaliza correctamente en este caso.

Conclusiones

El mejor modelo para la predicción de presencia alta y baja de cianobacterias con píxeles originales fue el XGBost, para cada una de las métricas usadas. Pero si se desea explicabilidad debe usarse la regresión logística, cuyo rendimiento solo fue 0.023 por debajo del XGBoost en la métrica f1-score.

Referencia

Chorus, I., & Welker, M. (2021). Exposure to cyanotoxins: Understanding it and short-term interventions to prevent it. In I. Chorus & M. Welker (Eds.), *Toxic cyanobacteria in water: A guide to their public health consequences, monitoring and management* (2nd ed., pp. 295–400). CRC Press. <https://doi.org/10.1201/9781003081449-5>

European Space Agency. (2025–2026). *Sentinel-2 Level-1C multispectral imagery of lakes Atitlán and Amatitlán, Guatemala* [Conjunto de datos]. Copernicus Data Space Ecosystem. <https://dataspace.copernicus.eu/>